

## ONDERZOEKSVOORSTEL

# Diepgaande Analyse van Geospatiale Veranderingen: Een Vergelijkende Studie van Machine Learning Modellen in Remote Sensing Change Detection voor de Vegetatie van Gent (2020-2024).

Bachelorproef, 2024-2025

Jona Fouquaert

E-mail: [jona.fouquaert@student.hogent.be](mailto:jona.fouquaert@student.hogent.be)

Co-promotor: C. Stal (Hogent, [cornelis.stal@hogent.be](mailto:cornelis.stal@hogent.be))

## Samenvatting

Geospatiale remote sensing biedt innovatieve methoden voor het monitoren van veranderingen in het landschap. Dit onderzoek richt zich specifiek op de detectie en visualisatie van veranderingen in vegetatiebedekking in de stad Gent tussen 2020 en 2024. Hiervoor worden Sentinel-2 satellietbeelden gebruikt en geanalyseerd met behulp van machine learning-technieken. Een geavanceerde machine learning-pijplijn wordt ontwikkeld om deze veranderingen te detecteren en te interpreteren. De onderzoeksmethode omvat een vergelijkende studie van diverse algoritmen, waaronder Support Vector Machines (SVM), Random Forests, Convolutional Neural Networks (CNN), Siamese Networks en Vision Transformers. Preprocessing van de data, zoals herschalen en semantische segmentatie, zorgt ervoor dat de inputdata consistent en geschikt is voor training. De algoritmen worden beoordeeld op nauwkeurigheid, consistentie en vermogen om visueel interpreteerbare resultaten te genereren. Een belangrijke evaluatie metriek is de Vegetation Condition Index (VCI), die veranderingen in vegetatiebedekking kwantificeert door Normalized Difference Vegetation Index (NDVI)-waarden te vergelijken. Daarnaast worden metriekeken zoals precision, recall en Intersection over Union (IoU) toegepast om de prestaties van de modellen te beoordelen. Het onderzoek beoogt niet alleen inzicht te bieden in de geschiktheid van verschillende machine learning-modellen voor geospatiale change detection, maar ook bij te dragen aan de toepassing van AI in stedelijke milieuanalyse en besluitvorming. Het onderzoek fungeert ook als oproep tot actie voor natuurbehoud in steden.

**Keuzerichting:** AI & Data Engineering

**Sleutelwoorden:** Change detection (CD), GEO-ICT, QGIS, Machine learning, Natuurbehoud

## Inhoudsopgave

1	Introductie . . . . .	1
2	State-of-the-art . . . . .	2
3	Methodologie . . . . .	2
4	Verwacht resultaat, conclusie. . . . .	3
	Referenties . . . . .	3

## 1. Introductie

Geo-ICT is de toepassing van informatie- en communicatietechnologie in de geografie. Een belangrijk component van Geo-ICT is het programma GIS. Geografische informatiesystemen (GIS) zijn digitale systemen die geografische gegevens analyseren, visualiseren en beheren om ruimtelijke patronen en relaties te begrijpen. Het wordt vandaag de dag door bedrijven gebruikt in verschillende sectoren. Nu er vraag is naar GIS-applicaties, zijn er ook ondernemingen die zich specialiseren in deze trend, zoals bijvoorbeeld het bedrijf GeoAI. Zij combineren Geo-ICT met het experimentele veld van machine learning. Dit kan ingezet worden om verschillende doeleinden te berei-

ken, zoals bijvoorbeeld automatische kaartgeneratie, voorspellende modellering, ...

Het thema waar ik me op focus is geospatiale remote sensing change detection. Dit gaat over het ontdekken van veranderingen in een bepaald landschap. Hier komt de sterkte van AI naar boven. Het is in staat patronen te ontdekken die wij als mensen moeilijk begrijpen. Deze studie is gericht op het bestuderen van de aanwezigheid van vegetatie in de stad Gent tussen de periode van 2020-2024. De dataset bestaat uit afbeeldingen genomen door de Sentinel 2 satelliet. Tijdens het onderzoek ga ik verschillende machine learning algoritmes (Support Vector Machines (SVM), Random Forests, Convolutional Neural Networks (CNNs), Siamese Networks en Vision transformer) testen op de dataset. Het model moet in staat zijn vegetatie te detecteren en ook het verschil tussen de twee periodes te visualiseren. Het open-sourceplatform QGIS wordt gebruikt om de data te verkrijgen en te visualiseren.

De onderzoeksvraag: Welk machine learning-model is het meest geschikt voor het nauwkeurig detecteren en visualiseren van de veranderingen in

aanwezigheid van vegetatie in de stad Gent tussen 2020 en 2024, met behulp van remote sensing change detection?

De deelvragen:

- Welke object klasse (vegetatie, bebouwing, wegen enz ...) toont de grootste veranderingen in percentage tussen de twee tijdstippen?
- Zijn er specifieke patronen in de veranderingen, zoals groei, afname of stabiliteit van groen in bepaalde delen van de stad?
- Zijn er ruimtelijke patronen in de veranderingen van vegetatie in de stad Gent?
- Is er een verschil tussen handmatige feature-extractie en automatische extractie op basis van deep learning, en wat is de impact hiervan op de resultaten?
- Welke evaluatie methoden zijn het meest geschikt om de prestaties van het model te beoordelen?
- Hoe wordt de balans gemeten tussen nauwkeurigheid en andere prestatie-indicatoren, zoals recall of precision?
- Welke criteria bepalen of een model als 'acceptabel' wordt beschouwd?
- Is één dataset voldoende om de generaliseerbaarheid van het model te garanderen?
- Hoe wordt omgegaan met mogelijke bias of beperkingen in de gebruikte datasets?
- Welke preprocessing-stappen zijn nodig om de datasets geschikt te maken voor model input?

## 2. State-of-the-art

Change detection (CD) is het waarnemen van verandering in een bepaald gebied aan de hand van afbeeldingen genomen op verschillende tijden (SINGH, 1989). Machine learning wordt al geruime tijd toegepast op CD. Maar in de laatste jaren heeft de opkomst van verschillende nieuwere algoritmen het veld verbreed. Zo worden verschillende studies gedaan rond de impact van deep learning neurale netwerken op CD, zoals het onderzoek van Bai e.a. (2022) over Deep Learning Change Detection (DLCD). Deep learning brengt een groot voordeel met zich mee, namelijk dat het in staat is om automatische feature extractie toe te passen op ruwe data zoals bewezen in de studie van LeCun e.a. (2015). De meest voorkomende algoritmen zijn de CNN, Vision transformer en Siamese neurale netwerken. Siamese networks zijn voor het eerst voorgesteld in het onderzoek van Bromley e.a. (1993). Het is een algoritme dat bestaat uit twee of meerdere identieke neurale netwerken met dezelfde weights en biases die samenkomen tot één output (Serrano & Bellogín, 2023). Een van de grootste voordelen ligt in het feit dat het in staat is accurate predicties te maken met weinig input data. Het wordt daarom ook wel het one-shot model genoemd (Koch e.a., 2015). Convolutional neurale netwerken worden

gezien als één van de beste machine learning algoritmes als het aankomt op visualisatietaken. De afbeelding wordt opgedeeld in kleine deeltjes aan de hand van filters, die dan allemaal geanalyseerd worden op een kleinere schaal (Géron, 2022). Dit maakt het ideaal om hiërarchische features en patronen te ontdekken in de input data. Transformers zijn neurale netwerken die uitsluitend bestaan uit attention layers voorgesteld in het onderzoek van Vaswani (2017). Attention is een methode om alleen relevante input data te verwerken in plaats van de hele batch (Géron, 2022). Dit vermindert de trainingstijd zonder de nauwkeurigheid van het model significant te beïnvloeden. Vision transformer (ViT) is een transformer gebouwd voor visuele taken. Oorspronkelijk geïntroduceerd in de studie van Dosovitskiy (2020). Vision Transformers (ViTs) zijn, dankzij de transformer-architectuur, bijzonder goed afgestemd op grootschalige datasets, wat bijdraagt aan hun huidige populariteit. Buiten deep learning zijn er ook nog andere AI modellen die gebruikt worden voor CD. Deze studie focust op twee modellen: Support Vector Machines (SVM) en Random Forests. SVM's, oorspronkelijk geïntroduceerd in het onderzoek van Cortes (1995), maken gebruik van feature extraction om zo een decision boundary (hyperlane) te bouwen die de veranderingen in het gebied scheidt van het onveranderde deel. Er zijn al verschillende studies gedaan rondom het gebruik van support vector machines voor CD, zoals Bovolo e.a. (2008) en Habib e.a. (2009). Random forests is een ensemble learning model dat bestaat uit meerdere decision trees, waarbij elke tree gebaseerd is op willekeurige vectoren met dezelfde verdeling (Breiman, 2001). Meerdere studies zoals Wessels e.a. (2016) en Feng e.a. (2018) tonen aan dat random Forest geschikt is voor change detection.

## 3. Methodologie

Het uiteindelijke doel van dit onderzoek is het ontwikkelen van een machine learning-pijplijn die effectief veranderingen kan detecteren tussen de aanwezigheid van vegetatie tussen twee tijdstippen. Dit is een vergelijkende studie, waarbij verschillende machine learning modellen getest worden. De eerste taak is het samenstellen van twee datasets opgebouwd uit satellietfoto's van Sentinel 2. Dataset 1 zal bestaan uit afbeeldingen van Gent in 2020 ( $t_1$ ). De tweede dataset bestaat uit satellietfoto's van Gent in 2024 ( $t_2$ ). Hiermee gaan we veranderingen proberen waar te nemen door ze te vergelijken met de afbeeldingen van  $t_1$  met behulp van machine learning. De datasets zijn opgedeeld in drie delen: training (60%), validatie (20%) en testing (20%). Training om het model te trainen. Validatie om te controleren hoe goed het model werkt op data die het niet eerder heeft

gezien. Dit zorgt ervoor dat het model beter generaliseerd tijdens de testing fase. Testing om het model te evalueren. Bovendien moet de dataset goed gerepresenteerd zijn, zodat de accuraatheid van het model niet lijdt onder gelijkaardige situaties (het model moet in staat zijn de objecten te detecteren tijdens de verschillende seizoenen). Elk vooraf gedefinieerd model wordt getraind en getest op de data. Het is niet de bedoeling om ze vanaf nul op te bouwen. Er wordt gebruik gemaakt van pretrained modellen. Dit deel van de studie zal herhaaldelijk worden toegepast op de dataset. Eerst passen we preprocessing toe op de datasets. In dit geval wordt herschalen toegepast om alle afbeeldingen dezelfde grootte te geven (Data Augmentatie). De data wordt gelabeld aan de hand van semantische segmentatie. Een computer vision taak waarbij elke pixel tot een bepaalde klasse/object wordt geclassificeerd. Dit resulteert in een segmentatie kaart waarin elk object (bv. vegetatie, gebouw, straat enz.) wordt aangeduid. Objecten van  $t_1$  worden vergeleken met objecten van  $t_2$ . De veranderingen worden gedetecteerd door gemiddelde kleur, grootte en verschil in vorm van een object. Vervolgens worden de verschillen tussen  $t_1$  en  $t_2$  geclassificeerd. Hierbij wordt niet alleen verandering aangeduid maar ook waarin objecten zijn veranderd. Voor de evaluatie worden een aantal metrieken gebruikt. De belangrijkste hieronder is de vegetation condition index (VCI). De VCI vergelijkt de NDVI-waarden van twee tijdstippen ( $t_1$  en  $t_2$ ) om veranderingen in vegetatiebedekking te berekenen. Andere evaluatie methoden zoals confusiematrix-methoden (precision en recall) en IoU (Intersection over Union) worden ook gebruikt. De twee belangrijkste python machine learning frameworks die gebruikt zullen worden tijdens deze studie zijn TensorFlow en scikit-learn.

#### 4. Verwacht resultaat, conclusie

Voor het technische aspect van deze studie wordt verwacht dat de deep learning modellen, zoals Convolutional Neural Networks (CNN), Vision Transformers en Siamese netwerken, betere prestaties zullen leveren in vergelijking met Support Vector Machines (SVM) en Random Forests. Recente onderzoeken ondersteunen deze verwachting door aan te tonen dat deep learning algoritmen doorgaans superieure resultaten behalen, met name bij complexe taken zoals geospatiale veranderingendetectie. Met betrekking tot de veranderingen in vegetatiebedekking binnen Gent wordt een lichte toename verwacht in vergelijking met 2020, gebaseerd op trends in stedelijke vergroening en gerelateerde ecologische initiatieven in de regio. Dit onderzoek gaat over het detecteren van ver-

anderingen in de vegetatie in een stedelijk gebied. Het is gericht naar organisaties die het behoud van de natuur op zich nemen. Zo kunnen rapporten met zulke studies een call to action worden voor het verder behouden van onze natuur.

#### Referenties

- Bai, T., Wang, L., Yin, D., Sun, K., Chen, Y., Li, W., & Li, D. (2022). Deep learning for change detection in remote sensing: a review. *Geospatial Information Science*, 26(3), 262–288. <https://doi.org/https://doi.org/10.1080/10095020.2022.2085633>
- Bovolo, F., Bruzzone, L., & Marconcini, M. (2008). A novel approach to unsupervised change detection based on a semisupervised SVM and a similarity measure. *IEEE transactions on geoscience and remote sensing*, 46(7), 2070–2082.
- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/https://doi.org/10.1023/A:1010933404324>
- Bromley, J., Guyon, I., LeCun, Y., Säckinger, E., & Shah, R. (1993). Signature Verification using a "Siamese" Time Delay Neural Network. In J. Cowan, G. Tesauro & J. Alspector (Red.), *Advances in Neural Information Processing Systems* (Deel 6). Morgan-Kaufmann. [https://proceedings.neurips.cc/paper\\_files/paper/1993/file/288cc0ff022877bd3df94bc9360Paper.pdf](https://proceedings.neurips.cc/paper_files/paper/1993/file/288cc0ff022877bd3df94bc9360Paper.pdf)
- Cortes, C. (1995). Support-Vector Networks. *Machine Learning*.
- Dosovitskiy, A. (2020). An image is worth 16x16 words: Transformers for image recognition at scale. *arXiv preprint arXiv:2010.11929*.
- Feng, W., Sui, H., Tu, J., Huang, W., & Sun, K. (2018). A novel change detection approach based on visual saliency and random forest from multi-temporal high-resolution remote-sensing images. *International Journal of Remote Sensing*, 39(22), 7998–8021. <https://doi.org/https://doi.org/10.1080/01431161.2018.1479794>
- Géron, A. (2022, oktober 1). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow, 3rd Edition*.
- Habib, T., Inglada, J., Mercier, G., & Chanussot, J. (2009). Support Vector Reduction in SVM Algorithm for Abrupt Change Detection in Remote Sensing. *IEEE Geoscience and Remote Sensing Letters*, 6(3), 606–610. <https://doi.org/10.1109/LGRS.2009.2020306>
- Koch, G., Zemel, R., Salakhutdinov, R., e.a. (2015). Siamese neural networks for one-shot image recognition. *ICML deep learning workshop*, 2(1).

- LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436–444. <https://doi.org/https://doi.org/10.1038/nature14539>
- Serrano, N., & Bellogín, A. (2023). Siamese neural networks in recommendation. *Neural Computing and Applications*, 35(19), 13941–13953. <https://doi.org/https://doi.org/10.1007/s00521-023-08610-0>
- SINGH, A. (1989). Review Article Digital change detection techniques using remotely-sensed data. *International Journal of Remote Sensing*, 10(6), 989–1003. <https://doi.org/https://doi.org/10.1080/01431168908903939>
- Vaswani, A. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*.
- Wessels, K., Van den Bergh, F., Roy, D., Salmon, B., Steenkamp, K., MacAlister, B., Swane-poel, D., & Jewitt, D. (2016). Rapid Land Cover Map Updates Using Change Detection and Robust Random Forest Classifiers. *Remote Sensing*, 8(11), 888. <https://doi.org/https://doi.org/10.3390/rs8110888>